

Relatório Técnico

Classificação de Câncer de Mama utilizando Machine Learning e Integração com LLM

1. Introdução

Este projeto tem como objetivo desenvolver uma solução baseada em Machine Learning para classificação de tumores de mama como benignos ou malignos utilizando o dataset público Breast Cancer Wisconsin.

Além da construção dos modelos preditivos, foi realizada uma integração com Large Language Models (LLMs) para interpretação dos resultados, análise crítica dos modelos, geração de explicações em linguagem natural e apoio à tomada de decisão.

O principal objetivo desta etapa do projeto foi avaliar como uma LLM pode atuar como uma camada complementar aos modelos tradicionais de Machine Learning, transformando resultados estatísticos e previsões numéricas em informações mais compreensíveis para usuários.

A solução desenvolvida busca demonstrar o potencial de integração entre modelos preditivos e modelos de linguagem, criando uma base para futuras aplicações envolvendo dados estruturados e não estruturados.

2. Base de Dados

Foi utilizado o dataset:

Breast Cancer Wisconsin Dataset

Fonte:

Kaggle - [uciml/breast-cancer-wisconsin-data](https://www.kaggle.com/uciml/breast-cancer-wisconsin-data)

A base contém características numéricas extraídas de imagens de tumores de mama.

A variável alvo original:

Valor original	Classificação
M	Maligno
B	Benigno

foi convertida para classificação binária:

Valor	Classe
1	Maligno
0	Benigno

A base possui informações relacionadas a características dos tumores, como:

- raio;
- textura;
- perímetro;
- área;
- suavidade;
- compactação;
- concavidade;
- simetria;
- dimensão fractal.

3. Tratamento e Preparação dos Dados

Foram realizadas as seguintes etapas:

Limpeza dos dados

Foi removida a coluna:

Unnamed: 32

por não possuir informações relevantes.

Também foram removidas:

- `id`, por representar apenas identificação da amostra;
- `diagnosis`, após criação da variável numérica de classificação.

Separação dos dados

Os dados foram divididos em:

- 80% para treinamento;
- 20% para teste.

Foi utilizada estratificação:

`stratify=y`

garantindo que a proporção entre casos benignos e malignos fosse mantida.

4. Análise Exploratória dos Dados

Antes da construção dos modelos foram realizadas análises estatísticas para compreender o comportamento da base.

Foram avaliados:

- estatísticas descritivas;
- matriz de correlação;
- heatmap geral;
- heatmap considerando apenas casos malignos.

Questão norteadora:

Como o tamanho da base de dados pode influenciar a confiabilidade das análises e previsões de possíveis casos de câncer de mama?

A análise demonstrou que, apesar dos resultados satisfatórios obtidos, o tamanho da base representa uma limitação para utilização em ambientes reais.

Bases maiores e mais diversificadas seriam necessárias para aumentar a capacidade de generalização do modelo e reduzir possíveis vieses.

5. Construção dos Modelos de Machine Learning

Foram desenvolvidos dois modelos:

- Regressão Logística;
- Árvore de Decisão.

A utilização de algoritmos diferentes teve como objetivo comparar abordagens distintas e posteriormente utilizar uma LLM para auxiliar na análise dos resultados.

6. Modelo 1 - Regressão Logística

Justificativa

A Regressão Logística foi escolhida por ser adequada para problemas de classificação binária.

O algoritmo aprende padrões existentes entre as características dos tumores e a variável de classificação, estimando a probabilidade de uma nova amostra pertencer à classe benigna ou maligna.

Questão norteadora:

Como a Regressão Logística utiliza as características dos tumores para prever possíveis casos de câncer de mama?

O modelo utiliza as variáveis de entrada para calcular uma probabilidade utilizando a função logística, permitindo classificar cada amostra em uma das duas categorias.

Pré-processamento

Como a Regressão Logística é sensível à escala das variáveis, foi aplicado:

`StandardScaler()`

Configuração utilizada:

`LogisticRegression(max_iter=5000)`

Resultados

Resultados obtidos:

Métrica	Resultado
Accuracy	0.9737
Precision	0.9756
Recall	0.9524
F1-score	0.9639

Matriz de Confusão:

```
[[71,1],  
 [2,40]]
```

O modelo apresentou:

- 71 classificações corretas de casos benignos;
- 40 classificações corretas de casos malignos;
- 1 falso positivo;
- 2 falsos negativos.

7. Modelo 2 - Árvore de Decisão

Justificativa

A Árvore de Decisão foi utilizada devido à sua capacidade de criar regras de decisão interpretáveis.

O modelo realiza divisões sucessivas utilizando características dos tumores para encontrar padrões de classificação.

Questão norteadora:

Como a Árvore de Decisão utiliza as características dos tumores para prever possíveis casos de câncer de mama?

A árvore identifica combinações de características que melhor separam as classes, criando uma estrutura de decisão baseada nos dados de treinamento.

Ajustes de Hiperparâmetros - LLM

Foi utilizado inicialmente:

`max_depth=6`

`min_samples_leaf=2`

Posteriormente, com apoio da LLM, foram avaliadas novas configurações:

- alteração do critério de divisão;
- ajuste da profundidade;
- controle de complexidade;
- balanceamento de classes.

A configuração escolhida após testes foi:

`max_depth=8`

Resultados

Métrica	Resultado
Accuracy	0.9298
ROC-AUC	0.9228
F1-score	0.9000

Matriz de Confusão:

$\begin{bmatrix} 70 & 2 \\ 6 & 36 \end{bmatrix}$

8. Comparação dos Modelos

Questão norteadora:

Como a comparação entre diferentes modelos de aprendizado de máquina pode contribuir para a identificação mais precisa de possíveis casos de câncer de mama?

A comparação permitiu avaliar não somente desempenho estatístico, mas também aspectos importantes para aplicações de saúde, principalmente a quantidade de falsos negativos.

Modelo	Accuracy	F1-score	Falsos Negativos
Regressão Logística	0.9737	0.9639	2
Árvore de Decisão	0.9298	0.9000	6

A Regressão Logística apresentou melhor desempenho geral e menor quantidade de erros críticos.

Por esse motivo, foi definida como modelo final.

9. Importância das Variáveis

Questão norteadora:

Quais características dos tumores exerceram maior influência na classificação dos possíveis casos de câncer de mama?

A análise de importância das variáveis permitiu identificar características relevantes para as decisões dos modelos.

Entre as principais variáveis identificadas estão:

- perimeter_worst;
- concave points_worst;
- texture_mean;
- texture_worst;
- area_worst;
- radius_worst.

Essa análise contribui para aumentar a interpretabilidade do modelo e compreender quais padrões influenciam a classificação.

10. Integração com LLM

Esta etapa representa o principal objetivo do exercício.

A LLM foi utilizada como uma camada complementar aos modelos de Machine Learning para:

- interpretar resultados;
- analisar métricas;
- sugerir melhorias;
- comparar modelos;
- gerar explicações em linguagem natural.

11. Engenharia de Prompt - Hiperparâmetros

Questão norteadora:

De que forma uma LLM pode contribuir para o aprimoramento dos modelos a partir dos resultados obtidos neste estudo?

Foram desenvolvidos prompts contendo:

- contexto do problema;
- descrição do modelo;
- características da base;
- métricas obtidas;
- matriz de confusão;
- importância das variáveis;
- objetivo específico da análise.

A estratégia utilizada buscou evitar respostas genéricas e direcionar a LLM para uma análise técnica baseada nos resultados apresentados.

12. APIs e Modelos de Linguagem Utilizados

Foram avaliadas duas integrações:

Gemini

A integração com Gemini foi implementada no código.

Entretanto, durante o desenvolvimento não foi possível realizar a execução completa utilizando a API Gemini devido às limitações relacionadas ao acesso da chave/API.

A implementação foi mantida para possibilitar futuras execuções por usuários que possuam acesso válido ao serviço.

Groq utilizando Llama

A integração principal utilizada foi realizada utilizando o modelo:

`llama-3.3-70b-versatile`

disponibilizado pela plataforma Groq.

Foi utilizada a versão disponível no contexto de acesso gratuito da API.

A Llama foi utilizada para:

- interpretação dos resultados dos modelos;
- análise crítica;
- recomendações de melhoria;
- comparação de hiperparâmetros;
- geração de explicações em linguagem natural.

13. Interpretação de Novos Casos utilizando LLM - Auxílio no entendimento pelo usuário

Foi desenvolvido um fluxo onde o usuário pode informar características de uma nova amostra.

O processo ocorre da seguinte forma:

Características informadas pelo usuário

|

v

Modelo Machine Learning

|

v

Probabilidade + classificação

|

v

LLM

|

v

Explicação em linguagem natural

A resposta gerada apresenta:

- classificação prevista;
- probabilidade estimada;
- explicação das características analisadas;
- limitações existentes.

A LLM funciona como uma interface de interpretação dos resultados do modelo.

14. Avaliação da Qualidade das Interpretações Geradas

Questão norteadora:

A utilização de uma LLM agregou valor à interpretação dos resultados obtidos pelos modelos tradicionais?

A avaliação demonstrou que a LLM contribuiu principalmente em três aspectos:

Tradução dos resultados técnicos

Transformou métricas estatísticas e probabilidades em explicações compreensíveis.

Apoio à tomada de decisão

Auxiliou na comparação entre modelos e identificação de pontos fortes e limitações.

Preparação para futuras integrações

A arquitetura criada permite evolução para utilização de dados textuais, como relatórios médicos e informações clínicas.

15. Uso Responsável da LLM e Considerações Éticas

Por envolver uma aplicação relacionada à saúde, a utilização da inteligência artificial deve considerar aspectos éticos e limitações.

A solução desenvolvida não realiza diagnóstico médico.

O resultado apresentado representa apenas uma previsão estatística baseada nos padrões aprendidos pelo modelo utilizando dados históricos.

A ferramenta deve ser utilizada como apoio à interpretação, não substituindo:

- avaliação médica;
- exames complementares;
- acompanhamento profissional.

A LLM deve auxiliar na compreensão dos resultados, evitando interpretações isoladas ou decisões tomadas exclusivamente com base na previsão do modelo.

Sempre deve ser incentivada a busca por profissionais de saúde qualificados para avaliação adequada de qualquer resultado ou suspeita clínica.

Também devem ser considerados:

- possíveis vieses existentes na base de dados;
- limitações de generalização;
- diferenças entre populações;
- necessidade de validação antes de qualquer aplicação real.

16. Limitações e Trabalhos Futuros

Principais limitações:

- tamanho reduzido da base utilizada;
- necessidade de validação externa;
- dependência da disponibilidade das APIs;
- necessidade de aprimoramento dos prompts.
- integração futura com dados textuais.

17. Conclusão

O projeto demonstrou a aplicação de Machine Learning para classificação de câncer de mama e a integração de uma LLM como ferramenta complementar para interpretação dos resultados.

A Regressão Logística apresentou melhor desempenho para o conjunto analisado, sendo escolhida como modelo final devido aos melhores indicadores estatísticos e menor quantidade de falsos negativos.

A integração com LLM agregou valor ao projeto ao permitir:

- análise crítica dos modelos;
- apoio na escolha de melhorias;
- interpretação dos resultados;
- geração de explicações em linguagem natural;
- criação de uma interface mais acessível para análise de novos casos.

A solução desenvolvida demonstra o potencial da combinação entre Machine Learning e modelos de linguagem, mantendo como princípio fundamental o uso responsável da inteligência artificial, especialmente em áreas sensíveis como a saúde.